

串流 ASR 模型比較報告

1. 測試音檔

項目	內容
案例數	50 條 TTS 生成
來源	凱基人壽客服情境腳本 — 理賠申請 / 保單變更 / 商品詢問 / 保單查詢 / 失效復效等
語言	繁體中文（國語）
格式	16 kHz mono WAV
噪音條件	clean / white 20dB / pink 20dB（3 種）
重複次數	每組合 2 次
總 runs	6 模型 × 50 cases × 3 noise × 2 repeats = 1800

2. 受測模型

代號	來源	框架
zipformer-zh-xl	sherpa-onnx-streaming-zipformer-zh-xlarge-int8-2025-06-30	sherpa-onnx
zipformer-zh-xl-t	sherpa-onnx-streaming-zipformer-ctc-zh-xlarge-int8-2025-06-30	sherpa-onnx
zipformer-zh-sm	sherpa-onnx-streaming-zipformer-zh-int8-2025-06-30	sherpa-onnx
zipformer-zh-sm-t	sherpa-onnx-streaming-zipformer-small-ctc-zh-int8-2025-04-01	sherpa-onnx
paraformer	sherpa-onnx-streaming-paraformer-bilingual-zh-en	sherpa-onnx
paraformer-tri	sherpa-onnx-streaming-paraformer-trilingual-zh-cantonese-en	sherpa-onnx

3. 實驗方式

- 每條音檔以 WebSocket chunk 串流方式餵入模型
- 紀錄逐字 partial / final 輸出與時間戳

- CER 計算：去標點空白後 Levenshtein / |ref|
- 噪音以指定 SNR 程序混入後重跑相同流程

指標定義

準確度類

指標	全名	計算方式	解讀
CER	Character Error Rate (字元錯誤率)	$\text{Levenshtein}(\text{ref}, \text{hyp}) \div \text{ref} $	把參考答案和模型輸出都去掉標點與空白，計算最少需要幾次「插入 / 刪除 / 替換」單字編輯才能把 hyp 變成 ref，再除以 ref 字數。CER 越低越好；一般 < 5% 為優、5–10% 可用、> 15% 偏差。
CER mean	平均 CER	所有 case 的 CER 取算術平均	反映整體平均表現，但容易被少數極差 case 拉高。
CER p50	CER 中位數	把所有 case CER 排序後取正中間值	反映「典型 case」的表現；不受極端 case 影響。若 mean 比 p50 高很多 → 代表分布偏斜，有災難級 case。
CER min / max	最佳 / 最差 case CER	50 條 case 中表現最好 / 最差那條	用來觀模型表現的下限與上限分布範圍。

延遲類 (串流模型才有意義)

Partial vs Final 概念：串流 ASR 在使用者說話過程中會不斷吐出**暫定的轉錄結果 (partial)**，等到偵測句子結束或信心足夠後，才把該段確定下來變成 **final**。partial 會持續被覆寫，final 不會被改。

指標	全名	計算方式	解讀
TTFP	Time to First Partial	音檔開始送進模型 → 第一個 partial 文字出現的毫秒數	使用者感受到的反應速度 — TTFP 越低，UI 上字幕越快出現。對話式應用建議 < 1000 ms；> 1500 ms 會感覺「卡住」。
TTFF	Time to First Final	音檔開始 → 第一個 final 出現的毫秒數	第一段話被「正式確認」要多久。TTFF 通常比 TTFP 高很多（要等句子結束 + endpoint 偵測）。
E2E	End-to-End latency	音檔開始 → 最後一個 final 出現的總毫秒數	整段轉錄完成的總時間。對 ~40 秒的音檔，E2E ≈ 42 秒表示「邊聽邊吐字、聽完隨即收尾」。
RTF	Real-Time Factor	$\text{E2E} \div \text{音檔長度}$	處理速度的相對指標。 RTF < 1.0 → 比即時更快（聽 1 秒處理 < 1 秒），可用於即時串流。RTF = 1.0 → 剛好即時。RTF > 1.0 → 比即時還慢，串流會持續積壓。

4. 整體準確度排名 (clean)

排名	模型	CER mean	CER p50	CER min	CER max
1	zipformer-zh-xl	10.70%	10.19%	7.14%	16.57%
2	zipformer-zh-xl-t	10.93%	10.57%	6.25%	17.68%
3	paraformer	11.17%	10.28%	6.49%	16.38%
4	zipformer-zh-sm-t	11.83%	11.44%	7.79%	17.13%
5	zipformer-zh-sm	13.28%	12.83%	7.78%	18.47%
6	paraformer-tri	14.02%	13.31%	8.38%	21.12%

5. 抗噪比較

模型	clean	white 20dB	pink 20dB	最差漲幅
zipformer-zh-xl	10.70%	11.32%	11.11%	+0.62%
zipformer-zh-xl-t	10.93%	12.57%	12.10%	+1.64%
paraformer	11.17%	11.32%	11.13%	+0.15%
zipformer-zh-sm-t	11.83%	13.48%	13.40%	+1.65%
zipformer-zh-sm	13.28%	13.78%	13.36%	+0.50%
paraformer-tri	14.02%	14.18%	13.73%	+0.16%

6. 延遲比較 (clean)

模型	TTFP (ms)	TTFF (ms)	E2E (ms)	RTF
zipformer-zh-sm	681	8381	41760	1.032
zipformer-zh-xl	728	8615	42023	1.038
zipformer-zh-sm-t	763	8517	41921	1.036
zipformer-zh-xl-t	800	8559	42100	1.040
paraformer	932	8500	41841	1.034
paraformer-tri	934	8495	41898	1.035

7. 各維度冠軍

維度	冠軍	數字
最高準確度	zipformer-zh-xl	clean CER 10.70%
最強抗噪	paraformer	white 漲幅 +0.15%
最快首字反應 (TTFP)	zipformer-zh-sm	681 ms